

Universidade de São Paulo
Escola de Artes, Ciências e Humanidades

ACH0021 – Tratamento e Análise de Dados e Informações – 1º sem. 2025

Professor: Dr. José Ricardo G. Mendonça

1ª Prova — BSI T. 64 — Data: 29 abr. 2025

Na resolução dos problemas, explique seu raciocínio e o que você está fazendo de forma que eu possa acompanhá-lo(a). Soluções “mágicas” ou “geniais” não serão aceitas sem explicações.

Problemas

1. Uma amostra de 30 quarteirões que compõem um bairro em desenvolvimento fornece a seguinte tabela com o número de casas por quarteirão:

48	35	12	35	24	40	7	22	38	32
4	40	93	34	29	18	78	18	49	15
20	15	29	61	11	44	52	23	19	39

- (a) Determine a média, a moda, a mediana e o desvio padrão do número de casas por quarteirão dessa amostra.

Vamos organizar os valores em ordem crescente:

4	7	11	12	15	15	18	18	19	20
22	23	24	29	29	32	34	35	35	38
39	40	40	44	48	49	52	61	78	93

A média aritmética dos valores observados é dada simplesmente por

$$\bar{x} = \frac{1}{30} \sum_{i=1}^{30} x_i = \frac{1}{30} (4 + 7 + \dots + 93) = \frac{984}{30} = 32,8.$$

Determinamos a mediana a partir do conjunto de dados ordenados como

$$\text{med}(x) = \frac{1}{2} (x_{(15)} + x_{(16)}) = \frac{1}{2} (29 + 32) = 30\frac{1}{2},$$

onde a notação $30\frac{1}{2}$ se lê “trinta e meio”. Finalmente, o conjunto de dados possui 5 modas distintas, cada uma com 2 incidências:

$$\text{mod}(x) = 15, 18, 29, 35 \text{ e } 40.$$

Para calcular o desvio padrão precisamos primeiro calcular a variância, dada por

$$\text{Var}(x) = \frac{1}{30} \sum_{i=1}^{30} (x_i - \bar{x})^2 = \frac{1}{30} \sum_{i=1}^{30} x_i^2 - \bar{x}^2 = \frac{1}{30} (4^2 + 7^2 + \dots + 93^2) - (30\frac{1}{2})^2 \simeq 392,6,$$

de forma que o desvio padrão do conjunto de dados vale $\text{sd}(x) = \sqrt{\text{Var}(x)} \simeq 19,8$.

- (b) Construa um histograma para o conjunto de dados da tabela. Use a regra de Sturges $k = 1 + \log_2 n \simeq 1 + \log_{10} n$ (arredondado para cima) para o número k de classes a ser empregado.

O enunciado do problema contém um erro: a regra de Sturges é dada por $k = 1 + \log_2 n \simeq 1 + 3,3 \log_{10} n$. Para $n = 30$ a regra sugere $1 + \log_2 30 \simeq 6$ intervalos de classe. Como o menor valor no conjunto de dados vale $x_{(1)} = 4$ e o maior vale $x_{(30)} = 93$, podemos usar um intervalo de classe uniforme de largura $\Delta = 16$, começando em $x = 0$ e indo até $x = k\Delta = 96$. A tabela dos dados agrupados é dada abaixo, onde $a \vdash b$ indica o intervalo $[a, b)$ fechado à esquerda e aberto à direita.

casas/quarteirão	n_i	$f_i = n_i/n$	$d_i = f_i/\Delta_i$
$0 \vdash 16$	6	0,200	0,0125
$16 \vdash 32$	9	0,300	0,0188
$32 \vdash 48$	9	0,300	0,0188
$48 \vdash 64$	4	0,133	0,0083
$64 \vdash 80$	1	0,033	0,0021
$80 \vdash 96$	1	0,033	0,0021
Total	30	0,999	$\sum_i d_i \Delta_i = 1,0016$

O histograma construído a partir dessa tabela de dados agrupados é dado abaixo.




Figura: Histograma do número de casas por quarteirão para o conjunto de dados do problema. Os percentuais acima de cada barra do histograma indicam a massa de frequência contida naquele intervalo.

- (c) Calcule novamente a mediana e o desvio padrão do conjunto de dados a partir da tabela de dados agrupados (ou, equivalentemente, a partir do histograma).

A mediana $\text{med}(x)$ é o valor que divide os valores observados em uma metade menor que $\text{med}(x)$ e outra metade maior que $\text{med}(x)$, isto é, $\text{med}(x)$ corresponde ao quantil de 50% da amostra.

Nos dados agrupados, acumulamos 50% da frequência relativa ao final do segundo intervalo de classe $16 \vdash 32$. Assim, podemos estimar a mediana a partir dos dados agrupados como $\text{med}(x) \simeq 32$, valor próximo ao da mediana $\text{med}(x) = 30\frac{1}{2}$ obtido diretamente a partir do conjunto de dados.

Para o cálculo do desvio padrão a partir dos dados agrupados precisamos primeiro calcular o valor da média a partir dos dados agrupados. Usando os pontos médios $\bar{x}_k$ de cada intervalo de classe ponderados pela massa de frequência contida no respectivo intervalo de classe obtemos

$$\bar{x} \simeq \sum_{k=1}^6 f_k \bar{x}_k = 0,2 \times 8 + 0,3 \times 24 + \dots + 0,033 \times 88 \simeq 33,5.$$

Esse valor é relativamente próximo ao da média $\bar{x} = 32,8$ calculada diretamente a partir do conjunto de dados.

2. A variância de um conjunto de dados $x_1, \dots, x_n$ é dada por $\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$, onde $\bar{x}$ é a média dos valores de x .

- (a) Mostre que a variância pode ser calculada como $\sigma^2 = \frac{1}{n} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$.

Basta desenvolver o produto na expressão para σ^2 :

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) = \frac{1}{n} \sum_{i=1}^n x_i^2 - 2\bar{x} \cdot \underbrace{\frac{1}{n} \sum_{i=1}^n x_i}_{\bar{x}} + \underbrace{\frac{1}{n} \sum_{i=1}^n \bar{x}^2}_{n\bar{x}^2}.$$

O segundo termo no lado direito da equação acima vale $-2\bar{x} \cdot \bar{x} = -2\bar{x}^2$ e o terceiro termo vale $\frac{1}{n} \cdot n\bar{x}^2 = \bar{x}^2$, de forma que juntando tudo obtemos

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2, \text{ ou ainda } \sigma^2 = \frac{1}{n} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right).$$

- (b) O que acontece com a média, a mediana e o desvio padrão de uma série de dados quando (i) cada observação é multiplicada por um número qualquer $a > 0$, (ii) subtrai-se a média geral $\bar{x}$ de cada observação x_i e (iii) subtrai-se a média geral $\bar{x}$ de cada observação x_i e divide-se o resultado pelo desvio padrão $\text{sd}(x)$?

(i) Se multiplicamos cada observação por $a > 0$ obtemos para a nova média a expressão $\bar{x}' = \frac{1}{n} \sum_i ax_i = a \frac{1}{n} \sum_i x_i = a\bar{x}$, e portanto a média é multiplicada por a . A mediana é dada ou por um dos valores x_i (quando n é ímpar) ou por uma média entre dois valores (quando n é par), de forma que a mediana também será multiplicada por a . Já se cada x_i for multiplicado por a obtemos o novo desvio padrão

$$\text{sd}(x') = \sqrt{\frac{1}{n} \sum_i (ax_i)^2 - (a\bar{x})^2} = a \sqrt{\frac{1}{n} \sum_i x_i^2 - \bar{x}^2} = a \text{sd}(x),$$

e o desvio padrão será multiplicado por a igualmente.

(ii) Obviamente se subtrairmos a média $\bar{x}$ de cada observação obtemos a nova média

$$\bar{x}' = \frac{1}{n} \sum_i (x_i - \bar{x}) = \frac{1}{n} \sum_i x_i - \bar{x} = 0.$$

A nova mediana simplesmente será dada por $\text{med}(x') = \text{med}(x) - \bar{x}$ sem nenhuma propriedade especial a menos que a distribuição dos dados seja simétrica—neste caso $\text{med}(x) = \bar{x}$ e $\text{med}(x') = 0$; raramente temos uma igualdade exata com dados reais, mas frequentemente temos $\text{med}(x) \simeq \bar{x}$. O desvio padrão será dado por

$$\text{sd}(x') = \sqrt{\sum_i (x_i - \bar{x})^2 - \bar{x}'^2},$$

mas como $\bar{x}' = 0$, obtemos

$$\text{sd}(x') = \sqrt{\sum_i (x_i - \bar{x})^2} = \text{sd}(x),$$

de maneira que o desvio padrão não se altera. De maneira geral, quando $x_i \rightarrow x'_i = x_i + a$, a média $\bar{x}'$ dos valores deslocados se torna

$$\bar{x}' = \frac{1}{n} \sum_{i=1}^n x'_i = \frac{1}{n} \sum_{i=1}^n (x_i + a) = \frac{1}{n} \sum_{i=1}^n x_i + \frac{1}{n} \sum_{i=1}^n a = \bar{x} + a,$$

isto é, a média se desloca como um todo por a , $\bar{x}' = \bar{x} + a$. Daí a variância σ'^2 dos valores deslocados se torna

$$\sigma'^2 = \frac{1}{n} \sum_{i=1}^n (x'_i - \bar{x}')^2 = \frac{1}{n} \sum_{i=1}^n (x_i + a - \bar{x} - a)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \sigma^2.$$

(iii) Juntando os resultados dos itens (i) e (ii), vemos que neste caso $\bar{x}' = 0$, $\text{sd}(x') = \text{sd}(x)/\text{sd}(x) = 1$ e a mediana será dada por $\text{med}(x') = (\text{med}(x) - \bar{x})/\text{sd}(x)$.

★ — ★ — ★